ورود به دنیای هوش‌مصنوعی

دوره‌ی مقدماتی و رایگان برای عموم علاقه‌مندان

جلسه‌ی هفتم: شبکه‌های عصبی مصنوعی، از نورون تا یادگیری عمیق

علی شریفی زارچی

رئیس کمیته‌ی علمی بین‌المللی المپیاد جهانی هوش‌مصنوعی

عضو کمیته‌ی علمی بین‌المللی المپیاد جهانی کامپیوتر

مرور آن‌چه تا امروز آموختیم

- مدل یادگیری ماشین: پیش‌بینی برچسب از روی ویژگی‌ها
- رگرسیون برای عدد پیوسته، دسته‌بندی برای برچسب گسسته
- آموزش مدل: چرخه‌ی حدس ← خطا ← اصلاح ← تکرار
- گرادیان کاهشی: کوه‌نوردی در مه به سمت کمترین خطا
- مدل‌های جلسات قبل: خط، درخت تصمیم، نزدیک‌ترین همسایه‌ها
- امروز: قدرتمندترین عضو خانواده، شبکه‌های عصبی مصنوعی

سوال کلیدی

مغز چطور تصاویر، صداها، زبان، و قواعد پیچیده را می‌فهمد؟

و آیا می‌شود از مغز برای ساخت هوش‌مصنوعی الهام گرفت؟

مسائلی که خط و درخت از پسشان برنمی‌آیند

تصویر

یک عکس ۱۰۰۰×۱۰۰۰ یعنی
یک میلیون ویژگی!
گربه در گوشه یا وسط، فرقی ندارد

صدا

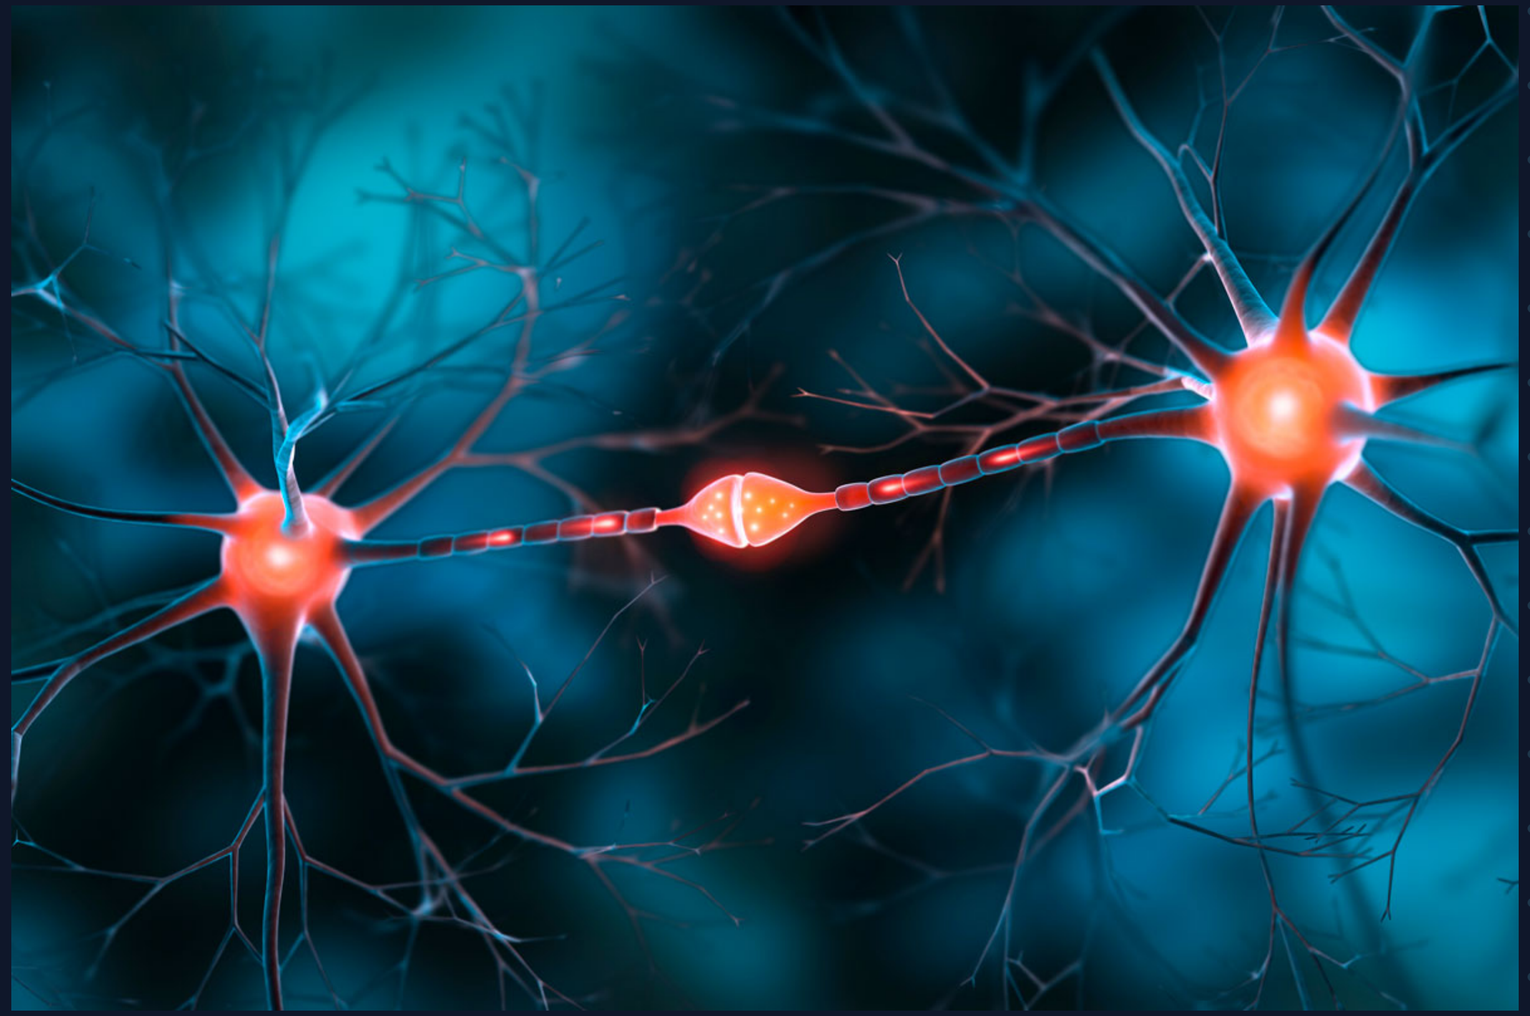
هزاران نمونه‌ی صوتی در ثانیه؛
لهجه‌ها و سرعت‌های متفاوت

زبان

معنی جمله به ترتیب و
بافت کلمات وابسته است

الگوهای این مسائل به‌شدت پیچیده و غیرخطی‌اند؛ برای آن‌ها به مدلی انعطاف‌پذیرتر نیاز داریم.

الهام از طبیعت: نورون مغز



https://mt-portal.de/aktuell/praezise-aufnahmen-enthuellen-die-vorgaenge-in-synapsen/

الهام از طبیعت: نورون مغز

در مغز شما

حدود ۸۶ میلیارد نورون به هم پیام می‌دهند
هر نورون از هزاران نورون دیگر ورودی می‌گیرد
اگر مجموع سیگنال‌ها کافی باشد، «شلیک» می‌کند

ایده‌ی سال ۱۹۴۳

مک‌کالک و پیتس: این رفتار را
می‌شود با جمع و ضرب ساده شبیه‌سازی کرد
نورون مصنوعی متولد شد

شبکه‌ی عصبی مصنوعی «کپی مغز» نیست؛ فقط از ایده‌ی آن الهام گرفته است.

نورون مصنوعی: همان داستان مغز، با اعداد



هر ورودی در «وزنِ» خودش ضرب می‌شود؛ اگر جمع امتیازها از آستانه بگذرد، نورون «فعال» می‌شود.

وزن یعنی اهمیت: هوای آفتابی (×۳) برای این تصمیم مهم‌تر از حال‌وحوصله (×۱) است.

یک نورون، با اعداد واقعی

امروز: هوا آفتابی (۱)، فردا تعطیل نیست (۰)، حال‌وحوصله دارم (۱)　　حد آستانه‌ی نورون: ۳

۱. ورودی‌ها × وزن‌ها

هوا: ۱ × ۳ = ۳

تعطیلی: ۰ × ۲ = ۰

حوصله: ۱ × ۱ = ۱

۲. جمع امتیازها

۳ + ۰ + ۱ = ۴

۳. مقایسه با آستانه

۴ ≥ ۳ ← نورون فعال!

تصمیم: برو پیک‌نیک

اگر هوا ابری بود (۰): جمع = ۱ که از آستانه‌ی ۳ کمتر است ← نورون خاموش: نرو.

«آموزش» یعنی ماشین خودش این وزن‌ها و آستانه را از داده پیدا کند، نه ما.

وزن و بایاس: دو پیچ تنظیم نورون

- وزن (Weight): اهمیت هر ورودی، هرچه بزرگ‌تر، آن ورودی در تصمیم موثرتر
- وزن منفی هم داریم: «باران می‌بارد؟» برای پیک‌نیک وزن منفی دارد!
- بایاس (Bias): سخت‌گیری یا آسان‌گیری نورون، همان جابه‌جا کردن آستانه
- نورون آسان‌گیر با کوچک‌ترین بهانه‌ای فعال می‌شود؛ نورون سخت‌گیر دلیل محکم می‌خواهد
- کل دانش شبکه در همین وزن‌ها و بایاس‌ها ذخیره می‌شود، نه جای دیگر

تابع فعال‌سازی: چاشنی غیرخطی

اگر همه‌چیز فقط جمع و ضرب باشد، هزار لایه هم که بچینیم حاصل باز یک خط ساده است!

سیگموید: کلید ملایم

$$\sigma(x) = 1 \div (1 + e^{-x})$$

خروجی را به صورت نرم، بین ۰ تا ۱ می‌برد

مثل ولوم صدا، نه کلید قطع/وصل

عالی برای بیان «احتمال»

ReLU: شیر یک‌طرفه

$$ReLU(x) = \max(x,0)$$

منفی‌ها را صفر می‌کند، مثبت‌ها را عبور می‌دهد

ساده و سریع؛ محبوب‌ترین انتخاب امروز

همین سادگی، آموزش شبکه‌های عمیق را ممکن کرد

غیرخطی‌بودن یعنی توانایی یادگیری الگوهای پیچیده: منحنی‌ها، مرزهای پیچ‌درپیچ، مفاهیم ترکیبی.

از امتیاز خام تا احتمال: Softmax

شبکه برای تصویر ورودی سه امتیاز خام (Logit) داده است — می‌خواهیم احتمال بسازیم

۱. امتیازهای خام

گربه: ۲٫۰

سگ: ۱٫۰

پرنده: ۰٫۱

۲. توان e

گربه: ۷٫۴

سگ: ۲٫۷

پرنده: ۱٫۱

(همه مثبت شدند)

۳. تقسیم بر مجموع (۱۱٫۲)

گربه: ۶۶٪

سگ: ۲۴٪

پرنده: ۱۰٪

جمع خروجی‌ها همیشه دقیقا ۱۰۰٪ است: یک توزیع احتمال واقعی.

نکته: فاصله‌ی امتیازها مهم است نه خودشان؛ امتیازهای ۱۲، ۱۱، ۱۰٫۱ همین احتمال‌ها را می‌دهند.

تابع هزینه‌ی دسته‌بندی: Cross-Entropy

Loss = -log(p)

احتمالی که مدل به کلاسِ درست داده = p

احتمال ۱۰۰٪ ← جریمه ۰؛ احتمال ۵۰٪ ← ۰٫۷

احتمال ۱٪ ← جریمه ۴٫۶

جریمه‌ی اعتمادبه‌نفس بی‌جا

اشتباهِ «با اطمینان کامل» به‌شدت تنبیه می‌شود

مثل معلمی که با اطمینان روی پاسخ غلط تاکید می‌کند.

برای دسته‌بندی از MSE بهتر است: سیگنال قوی‌تر

برچسب را چطور عدد کنیم؟ :One-hot

برچسب‌های گسسته ترتیب و فاصله ندارند؛ کدگذاری ما هم نباید داشته باشد.

راه اشتباه ❌

گربه=۰، سگ=۱، پرنده=۲

مدل خیال می‌کند پرنده «بزرگ‌تر»

از سگ است و گربه به سگ نزدیک‌تر!

راه درست: One-hot ✅

گربه = [۱, ۰, ۰]

سگ = [۰, ۱, ۰]

پرنده = [۰, ۰, ۱]

جفت طلایی

One-hot + Softmax + CE

در Loss فقط احتمال

کلاس درست باقی می‌ماند

از یک نورون به شبکه: لایه‌ها



شهود کلیدی: هر لایه، یک سطح از انتزاع

مثال: شبکه‌ای که تصویر گربه را تشخیص می‌دهد، هیچ‌کس به آن «لبه» یا «چشم» را یاد نداده است.

لایه‌های اول

از پیکسل‌های خام،

لبه‌ها و خط‌ها را می‌یابند

لایه‌های میانی

از لبه‌ها، اجزا را می‌سازند:

چشم، گوش، بینی

لایه‌های آخر

از اجزا، مفهوم کامل:

«این یک گربه است!»

این سلسله‌مراتب را خود شبکه در جریان آموزش کشف می‌کند؛ جادوی اصلی همین‌جاست.

سوال کلیدی

یک شبکه‌ی واقعی میلیون‌ها وزن دارد؛

چه کسی این همه پیچ را تنظیم می‌کند؟

چرخه‌ی یادگیری: همان داستان آشنا

۱. حدس

شبکه با وزن‌های تصادفی
شروع می‌کند و جواب می‌دهد:
«این سگ است» (اشتباه!)

۲. خطا

تابع هزینه می‌گوید
پاسخ چقدر با واقعیت
فاصله دارد

۳. اصلاح

هر وزن، کمی در جهت
کم‌شدن خطا تغییر می‌کند

این چرخه میلیون‌ها بار تکرار می‌شود، دقیقا همان «حدس، خطا، اصلاح، تکرار» جلسه‌ی دوم.

کوه‌نورد برمی‌گردد: گرادیان کاهشی

- همان کوه‌نوردی در مه، اما این‌بار نه روی دو پارامتر بلکه روی میلیون‌ها وزن
- موقعیت کوه‌نورد: مقدار فعلی همه‌ی وزن‌ها؛ ارتفاع: میزان خطای شبکه‌ی عصبی
- در هر قدم، همه‌ی وزن‌ها هم‌زمان کمی در جهت کاهش خطا حرکت می‌کنند
- نرخ یادگیری هنوز همان نقش را دارد: گام بزرگ ← پرش از دره؛ گام کوچک ← آموزش کند

پس‌انتشار خطا: تقسیم تقصیر

- تیم فوتبال باخته است؛ مربی چه می‌کند؟ سهم هر بازیکن از باخت را مشخص می‌کند
- پس‌انتشار (Backpropagation) همین است: خطا از خروجی به عقب برمی‌گردد
- هر وزن می‌فهمد چقدر در اشتباه نهایی «مقصر» بوده و به همان اندازه اصلاح می‌شود
- وزنی که نقش بزرگی در خطا داشته، تغییر بزرگ‌تری می‌کند؛ وزن کم‌تقصیر، تغییر کوچک

سوال کلیدی

معماری شبکه‌ی عصبی را برای مساله‌های مختلف چطور تغییر دهیم؟

معماری ۱: رگرسیون

چیدمان خروجی

۱ نورون خروجی (یا چند، برای چند عدد)

بدون فعال‌سازی — خروجی خطی و آزاد

Loss: میانگین مربع خطا (MSE)

مثال: قیمت خانه‌های تهران

خروجی باید هر عددی بتواند باشد

سیگموید اینجا سم است: خروجی را به (۰،۱) قفل می‌کند!

ویژگی‌ها ← لایه‌های ReLU ← یک عدد: قیمت

معماری ۲: دسته‌بندی دودویی

چیدمان خروجی

۱ نورون خروجی + سیگموید

خروجی: احتمال کلاس مثبت (۰ تا ۱)

Loss: باینری Cross-Entropy

مثال: تایتانیک

خروجی ۰٫۸ یعنی: ۸۰٪ زنده می‌ماند

آستانه‌ی تصمیم معمولا ۰٫۵ است

جابه‌جایی آستانه = بده‌بستان صحت و پوشش!

معماری ۳: دسته‌بندی چندکلاسه

چیدمان خروجی

به تعداد کلاس‌ها نورون خروجی + Softmax

برچسب‌ها به شکل One-hot

کراس‌انتروپی چندکلاسه :Loss

مثال: ارقام دست‌نویس MNIST

۱۰ نورون خروجی — یکی برای هر رقم

تصویر «۷» ← نورون هفتم باید ۱ شود

پیش‌بینی نهایی: نورونی با بیشترین احتمال

جمع‌بندی: معماری خروجی را مسئله تعیین می‌کند

مسئله	نورون‌های خروجی	فعال‌سازی خروجی	تابع هزینه
رگرسیون	۱ نورون	هیچ (خطی)	MSE
دسته‌بندی دودویی	۱ نورون	سیگموید	Binary Cross-Entropy
دسته‌بندی چندکلاسه	به تعداد کلاس‌ها	Softmax	Cross-Entropy + One-hot

مثال‌های آشنا: قیمت خانه‌های تهران — بازماندگان تایتانیک — ارقام دست‌نویس MNIST

لایه‌های پنهان در هر سه حالت یکسان‌اند (ReLU)؛ فقط «سرِ» شبکه عوض می‌شود.

شبکه‌های عصبی دور و بر شما

تصویر

باز شدن گوشی با چهره‌ی شما

دوربین پلاک‌خوان

تشخیص تومور در رادیولوژی

صدا

سیری و دستیارهای صوتی

تبدیل گفتار به متن

حذف نویز در تماس‌ها

زبان

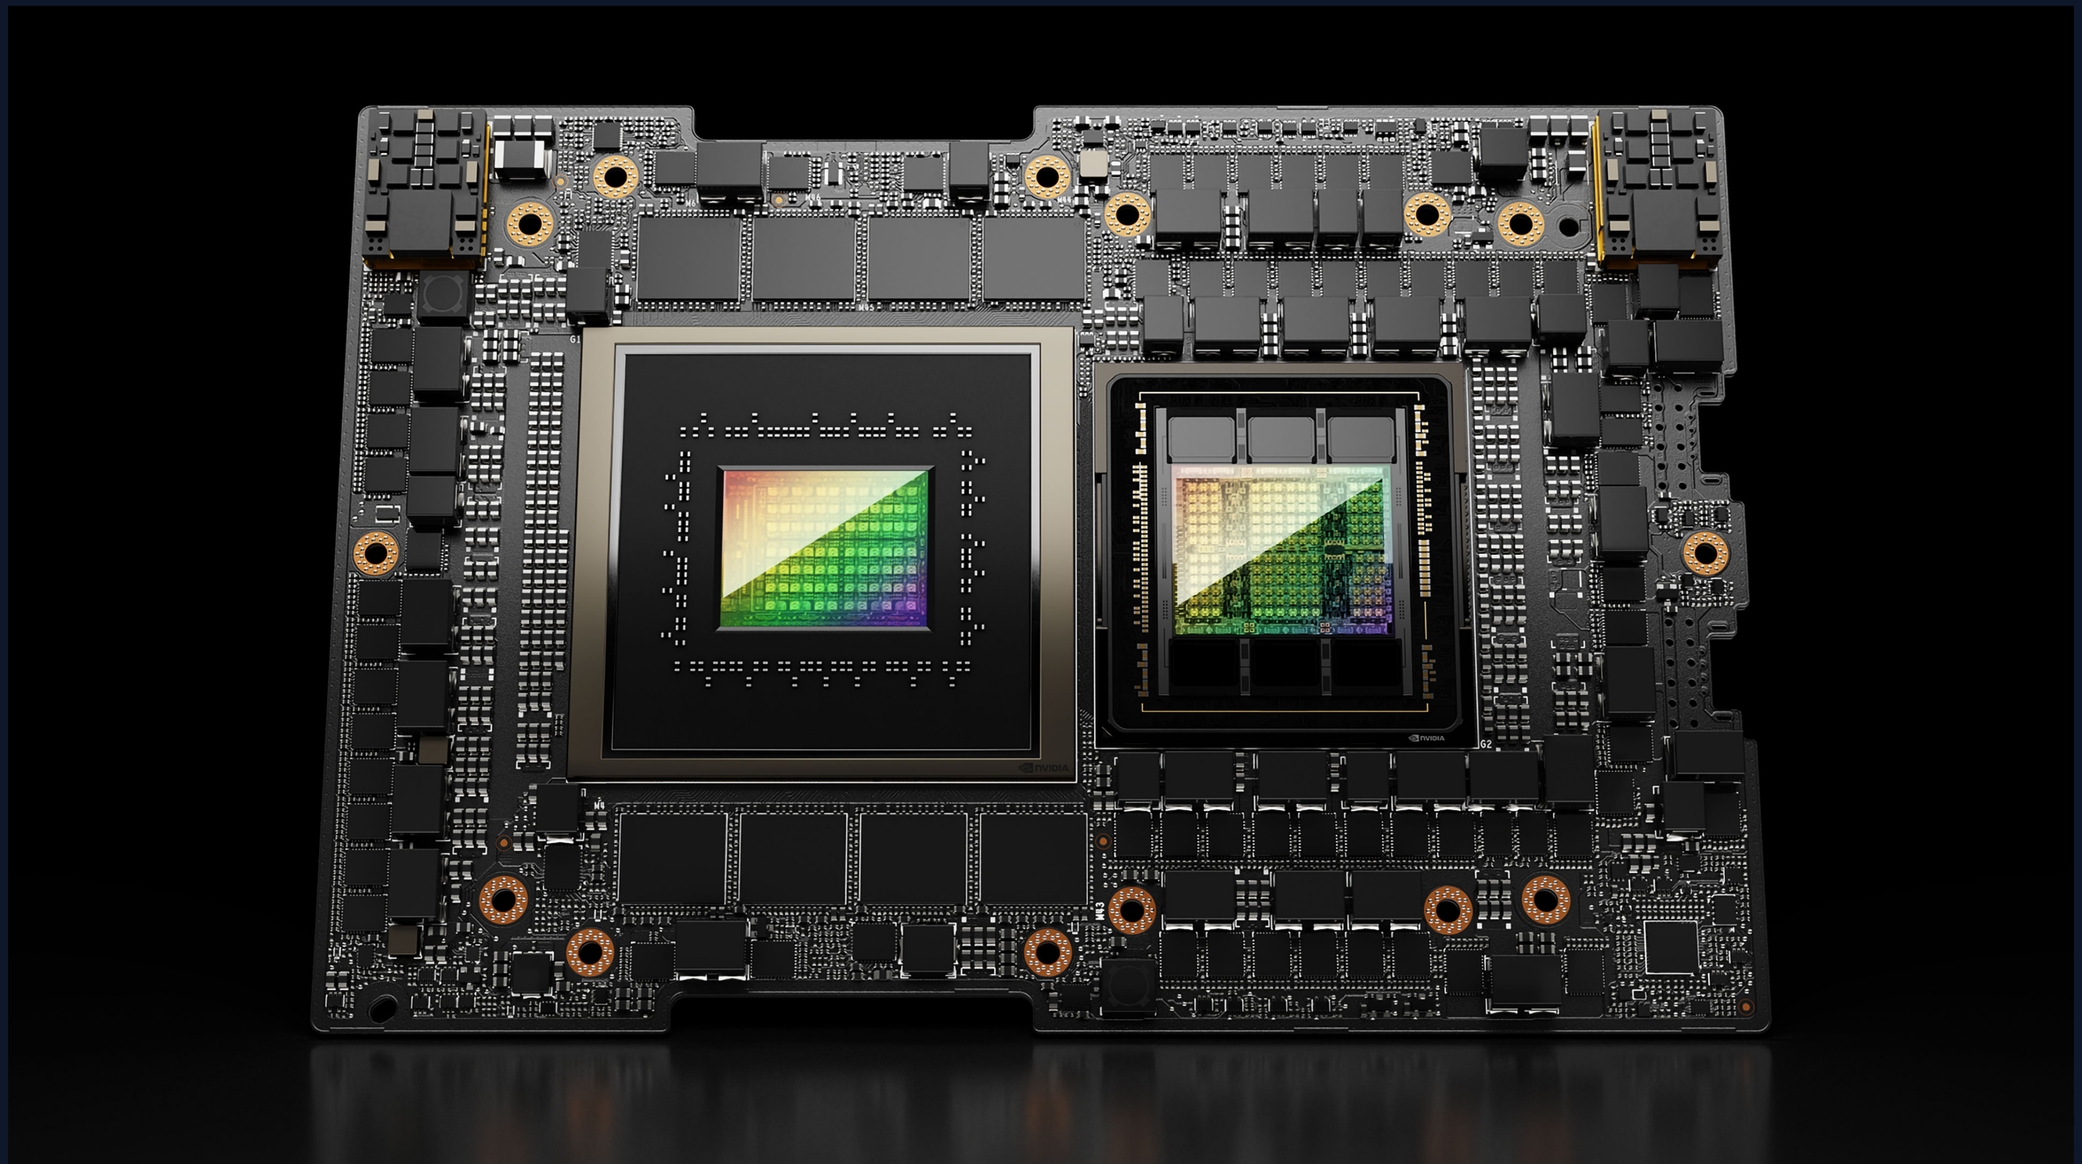
و مدل‌های زبانی ChatGPT

ترجمه‌ی ماشینی

خلاصه‌سازی و جست‌وجو

یادگیری عمیق (Deep Learning) یعنی همین شبکه‌ها، فقط با لایه‌های خیلی بیشتر؛ گاهی صدها لایه.

پردازنده‌ی گرافیکی (GPU)



چه چیزهایی هنوز برای شبکه‌های عصبی سخت است؟

- داده‌ی زیاد می‌خواهد: کودک با دیدن دو گربه یاد می‌گیرد؛ شبکه با میلیون‌ها تصویر
- انرژی و هزینه: آموزش مدل‌های بزرگ به هزاران GPU و برق یک شهر کوچک نیاز دارد
- جعبه‌ی سیاه: میلیون‌ها وزن را نمی‌شود مثل درخت تصمیم «خواند» و توضیح داد
- سوگیری داده را ارث می‌برد و گاهی با اعتمادبه‌نفس اشتباه می‌کند
- شناخت این ضعف‌ها همان‌قدر مهم است که شناخت قدرتش